

文献综述：中文文本风格迁移与关系感知生成研究

王浩楠 张博淞 范智杰 何顺康 陈佳铭

2026 年 6 月 21 日

摘要

文本风格迁移是自然语言生成领域的重要任务，旨在保持文本语义内容不变的同时改变其风格属性。现有研究多集中于情感极性、正式度、作者属性和文本体裁等风格维度，而对“说话对象”这一日常沟通中极为关键的社会语用变量关注不足。中文交流具有丰富的称呼系统、礼貌等级和亲疏表达方式，同一句话在面对老板、同事、朋友、恋人和家人时往往需要采用不同的语气与信息组织方式。因此，关系感知的中文文本风格迁移不仅具有应用价值，也为文本风格迁移研究提供了更细粒度的任务设定。

本文围绕“小样本条件下中文多角色文本风格迁移”这一研究主题，从五个方面梳理相关文献：第一，回顾文本风格迁移的任务定义、主流方法和评估指标；第二，分析中文对话数据集及其在角色风格标注方面的不足；第三，总结预训练语言模型、指令微调模型以及 mT5/mT0 等多语言 Seq2Seq 模型的发展；第四，讨论 LoRA 等参数高效微调技术在小样本生成任务中的优势；第五，从礼貌理论、语域理论和语言顺应论角度解释社会关系如何影响语言表达。最后，本文指出现有研究在中文关系角色风格迁移方向上的空白，并明确本项目的数据构建、模型训练和系统实现定位。

目录

1	引言	4
2	文本风格迁移研究	4
2.1	任务定义	4
2.2	有监督、无监督与弱监督路线	5
2.3	评价指标与任务难点	6
2.4	相关研究路线对比	6
2.5	本项目评价维度设计	7
3	中文对话数据资源	8
3.1	公开中文对话语料	8
3.2	关系角色标注缺口	9
3.3	数据质量问题	9
3.4	中文角色风格数据集构建思路	10
4	预训练模型与指令微调	11
4.1	T5 与文本到文本范式	11
4.2	mT5	11
4.3	mT0	11
4.4	指令微调范式的启发	12
5	参数高效微调技术	13
5.1	全量微调的局限	13
5.2	Adapter、Prefix-Tuning 与 Prompt-Tuning	13
5.3	LoRA	14
5.4	单 LoRA 与多 LoRA	14
6	语用学与关系感知生成	15
6.1	礼貌理论	15
6.2	语域理论	16
6.3	语言顺应论	16
7	研究不足与本文定位	16
7.1	现有研究不足	16
7.2	本项目定位	16
8	系统实现与数据闭环相关研究	18
8.1	Web 服务框架与模型推理调度	18

目录	3
8.2 数据持久化、认证与接口规范	18
8.3 用户反馈与增量训练闭环	19
9 结论	20

1 引言

语言表达不是孤立的信息编码过程，而是嵌入具体人际关系和交际场景中的社会行为。同一句事实内容，在不同对象面前往往需要采用不同表达方式。例如“我今天加班，可能晚点回去”对老板应突出工作安排和进度责任，对朋友可以自然随意，对恋人需要兼顾情绪安抚，对母亲则需要让长辈放心。这种差异体现了语言使用者对社会关系、礼貌规范和场景预期的综合判断。

自然语言处理中的文本风格迁移任务为建模这类现象提供了技术基础。早期研究主要关注情感极性转换，例如将负面评论改写为正面评论；也有研究关注正式度转换，例如将口语表达改写为书面表达。然而，“关系角色”这一风格维度更加复杂：它不仅包含正式度，还涉及权力差、亲密距离、称呼选择、情绪表达和信息优先级。因此，关系感知生成可被看作文本风格迁移、社会语言学和语用学交叉处的细粒度生成任务。

本项目聚焦中文场景下的多角色文本风格迁移，目标是在保持核心语义不变的情况下，根据目标对象生成合适表达。为支撑该任务，需要回答三个关键问题：

1. 如何构建包含多类关系对象的中文平行改写数据？
2. 在小样本条件下，如何选择合适的预训练模型和微调方式？
3. 如何评估改写结果是否同时满足语义保持、角色适配和自然流畅？

以下章节将围绕这些问题展开文献梳理。

2 文本风格迁移研究

2.1 任务定义

文本风格迁移（Text Style Transfer, TST）通常被定义为：给定源文本 x 和目标风格 s_t ，生成文本 y ，使得 y 在内容上与 x 保持一致，同时在风格上符合 s_t 。形式化表示为：

$$y = G_{\theta}(x, s_t)$$

其中， G_{θ} 是生成模型， s_t 可以是情感、正式度、作者属性、文本体裁或其他风格标签。该任务的难点在于“内容”和“风格”往往并非完全可分离。某些词语既承载语义，又带有风格信息，因此简单替换关键词可能导致语义损失或表达不自然。

在本项目中，目标风格不是单一标签，而是目标对象 r 及其对应的社会关系特征。它既包含正式度，也包含权力关系、亲密距离、称呼方式、情绪表达和信息组织策略。因此，本项目的生成结果需要同时满足三类约束：

- **语义保持**：不改变原句的时间、地点、人物、数量和核心事件。

- **角色适配**：表达方式符合目标对象的关系距离和礼貌预期。
- **自然流畅**：输出应是自然中文，而不是机械模板拼接。

2.2 有监督、无监督与弱监督路线

当存在平行语料时，文本风格迁移可以直接建模为 Seq2Seq 监督学习任务。模型输入源风格句子，输出目标风格句子。GYAFC 数据集是正式度迁移领域的代表性数据集，它收集了非正式句子及其正式改写版本，为有监督正式度迁移提供了标准基准 [11]。有监督方法的优点是训练目标明确，生成结果通常更稳定；缺点是平行数据构建成本高。对于中文关系角色风格迁移，天然平行语料几乎不存在：同一个人很少会将同一句话分别对老板、同事、朋友、恋人和母亲说一遍。因此，本项目无法直接依赖现成平行数据。

在缺乏平行语料的情况下，研究者提出了多种无监督风格迁移方法。Fu 等人较早探索了通过隐变量和风格分类器控制生成风格的路线 [12]；Shen 等人将非平行语料条件下的文本风格迁移建模为内容表示与风格表示的解耦问题，通过对抗训练约束隐变量表示尽量去除风格信息，再利用目标风格条件生成句子 [21]；John 等人进一步讨论了非平行文本风格迁移中的解耦表示学习问题 [13]。这些研究的共同目标是在缺少句对监督的情况下，让模型同时满足“内容保持”和“风格改变”两个要求。典型思路包括：

1. **风格内容解耦**：将文本表示分解为内容向量和风格向量，在生成时替换风格向量。
2. **对抗训练**：使用风格分类器约束生成文本符合目标风格，同时通过重构损失保持内容。
3. **回译与循环一致性**：通过源风格到目标风格再回到源风格的循环约束保持语义。
4. **伪平行数据生成**：利用规则或大语言模型构造近似平行样本。

无监督方法降低了数据需求，但在细粒度角色风格迁移中仍面临挑战。关系风格并非简单词表差异，模型需要根据对象判断哪些信息应突出、哪些表达应弱化。例如对老板表达时可能突出进度和责任，对母亲表达时可能突出安全和安抚。这类差异很难只靠风格分类器约束。Li 等人提出的 Delete, Retrieve, Generate 方法强调先删除风格片段，再检索目标风格表达并生成句子 [22]。这一思路说明，风格既可能体现在“您”“麻烦”“宝贝”“妈”等局部词汇上，也可能体现在整句的信息组织上。对本项目而言，如果模型只是替换称呼词，而没有调整礼貌程度和信息重点，就不能算完成了关系风格迁移。

近年来，大语言模型提示改写为风格迁移提供了新的弱监督路径。Reif 等人的研究表明，大语言模型可以通过自然语言提示完成较灵活的任意风格改写 [14]。但直接调用大模型也存在成本、稳定性、可控性和部署依赖问题。结合本项目的小样本和可部署要求，更合适的路线是“强教师模型生成候选数据 + 自动质检过滤 + 较小基座模型 LoRA

微调”：用大模型承担数据标注和多角色改写生成，用规则过滤降低事实漂移和模板化噪声，再让可本地部署的模型学习稳定的角色条件生成能力。

2.3 评价指标与任务难点

文本风格迁移通常从内容保持、风格准确和流畅自然三个维度评估。内容保持常用 BLEU、ROUGE、BERTScore 或语义相似度衡量；风格准确常用风格分类器判断；流畅自然可用语言模型困惑度或人工评分衡量。Mir 等人系统分析了文本风格迁移中的自动评价与人工评价问题，指出 BLEU、ROUGE、风格分类准确率和语言模型困惑度等指标只能覆盖部分质量维度，难以单独反映迁移结果的整体可用性 [23]。例如，较高的 BLEU 可能意味着模型保留了大量原句内容，但也可能说明模型没有完成有效迁移；较高的风格分类准确率可能来自几个强风格词，却不能保证语义没有漂移。

关系角色风格迁移进一步放大了这一评价难点。它的目标不是生成“看起来像某类角色”的句子，而是让同一个说话者在面对不同对象时表达得合适、自然且不改变原意。因此，本项目不能只检查是否出现角色关键词，也不能只依赖 ROUGE 一类重叠指标。更合理的评价应结合规则检查和人工评价：规则检查用于发现数字、时间、长度和相似度异常；人工评价用于判断语义保持、角色适配、自然流畅和角色区分等语用质量。

2.4 相关研究路线对比

为进一步明确本项目与已有文本风格迁移研究的关系，可从数据形式、建模方法和评估方式三个角度进行比较。表 1 总结了几类主要研究路线及其对本项目的启发。

表 1: 文本风格迁移相关研究路线对比

研究路线	典型任务	优点	局限及对本项目启发
有 监 督 Seq2Seq	GYAFC 正式度迁移 [11]	训练目标明确，输出稳定	依赖高质量平行语料；中文多角色平行数据缺乏，需要自建弱监督数据。
无监督风格迁移	Cross-Alignment、风格内容解耦 [21, 13]	不依赖平行语料，数据获取成本较低	细粒度关系风格难以只靠风格分类器约束，容易出现语义漂移。

研究路线	典型任务	优点	局限及对本项目启发
编辑与检索生成	Delete, Retrieve, Generate [22]	能显式处理部分风格词与内容词	角色风格不只体现在局部词汇，还涉及信息重点和语用策略。
大语言模型改写	任意风格提示改写 [14]	生成质量高，提示灵活	成本、可控性和稳定性不足；适合作为教师模型构造训练数据。
指令微调与PEFT	mT0、LoRA、Adapter	兼顾指令理解、训练成本和部署可行性	小样本下仍依赖数据质量和评价体系，需避免只学到模板称呼。

2.5 本项目评价维度设计

结合上述研究，本项目的评价可分为自动规则检查和人工评价两类。自动规则检查主要面向事实保持和数据质量，例如数字、时间词、长度比例和角色间相似度；人工评价则面向自动指标难以覆盖的语用合理性，例如说话对象是否合适、语气是否自然、是否存在过度亲密或过度正式等问题。

表 2: 关系风格迁移评价维度

评价维度	关注问题	可采用方法
语义保持	是否保留原句核心事实、时间、数量和事件关系	数字/时间规则检查，人工 1-5 分评分
角色适配	是否符合老板、同事、朋友、恋人、母亲等对象预期	人工评分，错误案例归类
自然流畅	是否符合中文日常表达习惯	人工评分，低质量样例分析
角色区分	五类角色输出是否真正存在语气和信息组织差异	角色间相似度，横向样例对比

为使评价结果更贴合关系感知文本风格迁移任务，本项目可采用 1-5 分人工评分方式，对每条生成结果分别从语义保持、角色适配、自然流畅和礼貌关系合理性四个方面

打分。其中，1 分表示严重不符合要求，3 分表示基本可接受但存在明显问题，5 分表示质量较高且可直接用于真实交流场景。评分时应尽量以原句和目标对象为依据，而不是只判断句子本身是否通顺。

表 3: 人工评价表建议

评价项	评分依据	常见扣分情况
语义保持	是否保留原句中的核心事件、人物、时间、地点、数量和因果关系	增加不存在的信息；遗漏时间或数字；改变说话者意图
角色适配	是否符合目标对象对应的亲疏关系、礼貌程度和表达习惯	对老板过于随意；对朋友过于正式；对母亲缺少安抚
自然流畅	是否符合中文日常表达习惯，读起来是否自然	句式生硬；模板痕迹明显；口吻不连贯
礼貌关系合理性	是否存在过度亲密、过度疏离、冒犯或不符合关系预期的表达	称呼不当；语气冒犯；情绪表达与对象关系不匹配

除单条评分外，还可以对同一原句下的五个角色输出进行横向比较，观察模型是否真正学到了角色区分。如果五类输出只是在开头替换称呼，而主体句式和语气几乎完全一致，则说明模型可能只学到了表层模板；如果五类输出在称呼、礼貌程度、情绪安抚和信息重点上都有合理差异，同时没有改变事实内容，则说明迁移效果更符合本项目目标。由此，本项目的评价重点应从“是否像某种抽象风格”扩展为“是否适合对这个对象说”。

3 中文对话数据资源

3.1 公开中文对话语料

中文对话生成研究中常用的数据包括 LCCC、豆瓣多轮对话、微博短文本对话、E-commerce 客服对话等。其中 LCCC [15] 是较有代表性的中文短文本对话语料，包含 base 和 large 两个版本，规模分别达到数百万级和千万级对话。该数据集由大规模中文短文本对话清洗而成，并通过规则和人工标注训练的分类器进行质量控制，覆盖日常生活、情绪表达、工作学习、出行安排等多类场景，适合作为本项目的原始语料来源。

LCCC 对本项目的直接启发有两点。第一，关系风格迁移的源句应尽量来自真实中文日常表达，而不是新闻、百科或过于书面化的语料；因此项目从 LCCC 中筛选第一人称中性句，可以提高原句的自然度和生活化程度。第二，LCCC 虽然经过清洗，但其目

标是支撑中文开放域对话建模，并未标注说话对象、社会关系和角色语气，也没有提供“同一语义面对不同对象”的平行改写。因此，直接使用 LCCC 训练模型无法得到关系风格迁移能力，需要额外进行中性句抽取和角色改写标注。

豆瓣多轮对话语料常用于中文多轮回复选择研究。Wu 等人提出的 Sequential Matching Network 使用多轮上下文与候选回复进行匹配，强调如何保留轮次关系和上下文信息 [16]。这类研究说明，中文对话数据能够为模型提供真实的上下文和回复关系，但其标注目标主要是“某个回复是否适合作为当前上下文的回答”，而不是“同一事实内容对不同关系对象应如何表达”。因此，豆瓣多轮对话等资源可以证明中文对话数据的可用性，同时也反衬出本项目所需的关系角色平行数据仍然缺乏。

3.2 关系角色标注缺口

现有中文数据集多面向情感分析、文本分类、问答、摘要和开放域对话，较少包含“同一语义面对不同关系对象”的平行表达。即使在对话数据集中，角色信息也通常体现为说话人身份、轮次顺序、上下文回复关系或客服/用户身份，而不是“说话者对目标对象的表达策略”。

本项目中的“角色”并不是让模型扮演老板、同事、朋友、恋人或母亲，而是要求说话者始终保持为“我”，并根据目标对象调整称呼、礼貌程度、情绪表达和信息组织方式。例如“我今天加班，可能晚点回去”面对老板时更适合强调进度和责任，面对同事时强调协作安排，面对女朋友时强调安抚和在意，面对母亲时强调让长辈放心。这种角色条件不是传统对话轮次标注能够直接提供的。

这造成两个问题：

1. 缺乏可直接训练关系风格迁移模型的中文数据。
2. 缺乏标准评估集，难以横向比较不同方法。

本项目的数据构建工作正是为了弥补这一缺口。通过从 LCCC 抽取第一人称中性句，再用教师模型生成五类角色改写，项目构建了一个面向中文关系风格迁移的弱监督数据集。该数据集不只关注“生成一句通顺的话”，而是强调同一原句在五类目标对象下的差异化表达，因此更贴近关系感知文本风格迁移的任务需求。

3.3 数据质量问题

大语言模型生成数据具有成本低、规模可控、格式灵活的优势，但也会引入质量问题。常见问题包括事实增删、语义漂移、输出模板化、角色差异不足和不合适内容误改写等。因此，近年来“LLM 生成数据 + 质量过滤”成为小样本任务中的常见策略。Self-Instruct [17] 展示了一种几乎不依赖人工标注的指令数据构建路线：先由语言模型生成指令、输入和输出样本，再过滤无效或相似样本，最后用过滤后的数据进行指令微

调。这一思路对本项目有直接启发，即可以把强模型作为教师模型，用其生成角色改写数据，但必须配合格式校验和质量过滤，避免下游小模型学习到噪声。

本项目的质量过滤规则具有任务针对性。例如，数字和时间信息在日常表达中常是核心事实，不能因风格迁移而丢失；称呼词虽然能体现角色，但如果只是添加称呼而不调整表达结构，则不能算高质量迁移。基于这一考虑，项目在 `dataset/quality_filter.py` 中设置了长度阈值、数字一致性、时间关键词一致性、ROUGE-L 相似度、模板词检测和角色间相似度等规则。这些规则将语言学直觉转化为可执行的数据清洗逻辑，使弱监督数据不仅有规模，而且有基本的事实保持和角色区分保障。

3.4 中文角色风格数据集构建思路

由于缺少可直接使用的中文多角色平行语料，本项目采用“公开对话语料筛选 + 教师模型弱标注 + 自动质检过滤”的构建路线。该路线的关键不是简单扩大样本规模，而是控制源句的可改写性和目标句的事实一致性。其流程可以概括为四步。

1. **源句筛选**：从 LCCC 中抽取 8–65 字之间、包含第一人称“我”、具有时间安排、工作学习、出行、状态或计划等信息量的中性句；同时过滤显式角色称呼、强情绪、广告、脏话、纯疑问和性别身份冲突等样本。
2. **教师改写**：使用 DeepSeek 作为教师模型，对每条中性句生成老板、同事、好朋友、女朋友和母亲五类目标对象下的改写；提示词明确要求说话者始终是“我”，角色表示说话对象，而不是让模型扮演该角色。
3. **质量过滤**：对每个角色改写单独检查事实保持和角色区分。如果某一角色输出不合格，仅将该角色置为 N/A，而不是丢弃整条源句，从而减少数据浪费。
4. **训练转换**：将过滤后的样本转换为 mT0-LoRA 使用的统一输入格式，即“任务、对象、风格、原句、改写”。这种格式与后端推理模板一致，便于模型学习角色条件生成。

从实际数据统计看，项目从原始语料中得到 2000 条中性候选句，过滤后保留 1966 条样本条目，形成 8957 条有效角色改写，并过滤 1043 条风险较高的角色改写；最终训练集、验证集和测试集分别为 7165、895 和 897 条。结合 LCCC 的自然表达优势、豆瓣多轮对话研究体现的中文对话建模基础，以及 Self-Instruct 对“生成数据 + 过滤 + 微调”路线的启发，本项目的数据构建思路可以概括为：以公开中文对话语料保证源句自然性，以教师模型降低平行标注成本，以规则过滤控制事实漂移和模板化风险，最终形成适合小样本 LoRA 微调的中文角色风格弱监督数据。

表 4: 中文角色风格数据构建要点

环节	主要目标	需要说明的内容
源句筛选	获得可面向多对象表达的中性句	句长、第一人称、强情绪、广告和已含角色称呼的过滤规则。
角色设定	明确目标对象差异	五类对象的权力关系、亲密程度、典型表达重点。
教师改写	生成弱监督平行样本	提示词、输出格式、N/A 处理和批量生成策略。
质量过滤	降低语义漂移和模板化问题	数字、时间、长度、相似度、模板词和角色间相似度检查。

4 预训练模型与指令微调

4.1 T5 与文本到文本范式

T5 [1] 将各种自然语言处理任务统一为文本到文本格式，即输入和输出都是字符串。这种范式适合风格迁移任务，因为改写本质上就是从源文本生成目标文本。原始 T5 主要面向英文语料，在中文任务上能力有限，因此中文或多语言场景通常采用 mT5、mBART、Chinese-T5 等模型。

4.2 mT5

mT5 [2] 是大规模多语言文本到文本预训练模型，覆盖包括中文在内的 101 种语言。它继承了 T5 的 Seq2Seq 架构，在 mC4 多语言语料上预训练，可用于翻译、摘要、问答和改写等任务。对于中文风格迁移，mT5 的优势在于具备多语言生成能力；不足在于它本身并未专门接受指令式任务训练，对“任务、对象、风格、原句、改写”这类字段的理解主要依赖下游微调数据。

4.3 mT0

mT0 [3] 可以看作在 mT5 基础上进行多任务指令微调后的模型，在 xP3 多语言指令数据集上训练，覆盖 46 种语言和多种任务类型。Sanh 等人证明，经过多任务提示训练后，模型能够在完全未见过的任务上实现零样本泛化，且英文任务的泛化能力可迁移至其他语言。这一特性对本项目尤为关键：mT0 不需要重新学习“按照指令改写文本”这一基础能力，可以更专注于学习中文场景下的角色风格差异。例如：

```
1 任务：保持原意，按目标对象改写语气。  
2 对象：老板  
3 风格：正式、礼貌、克制  
4 原句：我今天加班，可能晚点回去  
5 改写：
```

对于本项目而言，mT0 的优势在于它更容易利用输入中的“任务”和“风格”字段，在小样本条件下比纯 mT5 更适合作为基座模型。需要注意的是，mT0 仍然不是对话式大模型，它对具体角色语气的掌握仍取决于微调数据质量。因此，本项目采用“短指令模板 + 角色风格词 + LoRA 微调”的方式，将 mT0 的指令理解能力和本项目数据结合起来。

4.4 指令微调范式的启发

指令微调（Instruction Tuning）通过在多样化任务指令上训练模型，显著提升了语言模型对自然语言任务描述的泛化能力。FLAN [4] 首次系统证明了这一点：在 62 个任务集群上做指令微调后，模型在未见任务上的零样本性能大幅提升。后续工作 [5] 进一步探索了指令微调的规模化规律，发现更大的基座模型、更多的任务簇和思维链数据能够产生更强的泛化能力。

这一范式对本项目有三层启发：

- 指令模板即任务定义：**本项目将“关系角色风格迁移”定义为一条自然语言指令（“任务：保持原意，按目标对象改写语气”），而非设计专门的模型结构或损失函数。这种方法利用了 mT0 在多语言指令微调中获得的任务泛化能力，使角色条件控制完全通过输入字段实现。
- 少样本泛化潜力：**FLAN 研究表明指令微调模型在少样本设置下显著优于纯预训练模型。在本项目中，每个角色仅有数百条训练样本，mT0 的指令遵循能力可以弥补数据量的不足，降低对大规模平行数据的依赖。
- 规模与性能的权衡：**Chung 等人指出指令微调的收益随模型规模递增。本项目选择 mT0-large（约 1.2B 参数）而非更小的 mT0-base，正是为了在单卡可训练的前提下尽可能保留指令泛化能力。

表 5: 基座模型路线对比

维度	mT5-large	mT0-large	本项目选择理由
预训练语料	mC4 多语言语料	mC4 + xP3 指令数据	指令数据赋予任务理解能力
中文生成能力	中等(多语言共享参数)	中等偏上(指令增强泛化)	指令格式有助于中文风格字段解析
指令遵循能力	弱(依赖下游数据归纳)	较强(预训练获得)	小样本条件下指令能力决定任务适配上限
少样本改写效果	需较多样本微调	零/少样本即可调整	每个角色仅数百样本时 mT0 更稳定
参数规模	约 738M	约 1.2B	mT0-large 在单卡 +LoRA 下仍可训练
角色条件控制	需设计专用格式	天然适配指令模板	对象/风格字段可嵌入输入模板

如表 5 所示, mT0-large 在指令遵循和少样本改写两方面优于 mT5-large。虽然 mT0 的参数规模更大(约 1.2B), 但配合 LoRA 参数高效微调后, 单张 24GB 显存的消费级 GPU 即可完成训练。此外, mT0 内置的指令理解能力使其能够区分“老板”的正式克制、“女朋友”的亲密安抚和“母亲”的尊重温暖, 这些角色差异通过输入模板中的“对象”和“风格”字段传达, 而非依赖模型自行从数据中归纳。这一选择背后的技术逻辑是: 在小样本条件下, 模型已有的结构化输入理解能力比从零学习更可靠。

5 参数高效微调技术

5.1 全量微调的局限

全量微调需要更新预训练模型全部参数, 计算和存储成本较高。对于 mT0-large 这类数亿参数模型, 全量微调不仅显存需求大, 也容易在小样本数据上过拟合。此外, 如果为不同角色保存多个完整模型, 部署和维护成本也会迅速上升。

5.2 Adapter、Prefix-Tuning 与 Prompt-Tuning

Adapter 方法 [6] 在 Transformer 层中插入小型可训练模块(通常为两层前馈网络加非线性激活), 只更新这些模块参数, 而保持预训练参数不变。Prefix-Tuning [7] 在输

入序列前添加可学习的连续向量（前缀），通过优化这些前缀来控制生成行为。Prompt-Tuning [8] 则进一步简化，仅学习少量软提示嵌入向量，在模型规模足够大时能达到与全量微调相近的效果。这些方法都属于参数高效微调（Parameter-Efficient Fine-Tuning, PEFT），核心目标是在冻结大部分预训练参数的情况下适配下游任务，显著降低训练和部署成本。

这些方法的共同优势是训练成本低、部署灵活，每个任务只需保存少量参数。但也存在不足：Adapter 的串行插入会增加推理延迟；Prefix-Tuning 和 Prompt-Tuning 对任务格式和模型规模较敏感，在中等规模模型上的效果可能不够稳定。

5.3 LoRA

LoRA（Low-Rank Adaptation）[9] 通过低秩矩阵分解建模权重增量，不直接修改原始权重。设原模型权重为 W ，LoRA 学习：

$$\Delta W = BA$$

其中 A 和 B 是低秩矩阵。训练时只更新 A 和 B ，推理时将低秩增量作用于原模型。LoRA 的优点包括：

- 可训练参数少，显存占用低。
- 适配器文件小，便于保存和切换。
- 保留预训练模型原有语言能力。
- 与 Seq2Seq 生成任务兼容性较好。

5.4 单 LoRA 与多 LoRA

对于多角色风格迁移，可以有两种方案：

1. **多 LoRA**：每个角色训练一个独立的 LoRA 适配器，推理时按角色切换对应的适配器权重。
2. **单 LoRA**：所有角色共享一个 LoRA 适配器，输入中显式加入角色条件（“对象”和“风格”字段）。

多 LoRA 结构清晰直观，每个适配器专注于单一角色的风格特征，理论上可以学到更精准的角色表达。然而，其实际局限性在小样本条件下尤为突出：

- **数据稀疏**：每个 LoRA 适配器只能使用对应角色的训练数据，样本量不足时容易过拟合到表面模板（如对所有“老板”改写只加“领导”一词），而非学习真实的风格差异。

- **管理复杂**：五个角色需要维护五组 LoRA 权重，部署时需要额外的切换逻辑和存储空间。
- **知识割裂**：不同角色的 LoRA 各自独立训练，无法共享语义保持、中文自然表达等通用能力，可能出现同一个原句在不同角色下语义不一致的问题。

单 LoRA 方案则能克服上述局限：所有角色数据共同训练一个适配器，使模型在“保持语义 → 根据对象调整表达”这一复合能力上获得更多训练信号。角色区分通过输入中的“对象”和“风格”字段实现——这正是 mT0 擅长的指令遵循能力。

此外，Pfeiffer 等人 [10] 在 AdapterFusion 中指出，多个独立适配器的简单切换存在知识干扰问题：不同适配器学到的是该任务的专用解，组合时可能冲突。AdapterFusion 提出了通过注意力机制融合多个适配器的方法，但这也意味着额外的训练和推理复杂度。这一发现为本项目选择单 LoRA 方案提供了参考：与其为五个角色维护和融合多个适配器，不如让模型通过一个共享适配器学习“条件生成”能力，由输入中的角色字段控制输出。

因此，本项目最终采用 mT0-large + 单 LoRA 的方案。这一选择的本质逻辑是：在小样本条件下，让模型学习“根据输入条件生成合适表达”这一通用能力，比让模型为每个角色单独学习一套表达规则更为可靠和高效。实际训练中 LoRA rank 设为 16、alpha 设为 32，在约 5,000 条训练样本上训练 3-8 个 epoch，可训练参数仅占模型总参数的约 0.2%。

6 语用学与关系感知生成

6.1 礼貌理论

Brown 和 Levinson 的礼貌理论指出，语言表达会受到权力差（Power）、社会距离（Distance）和行为强加程度（Rank）的影响。说话者面对上级时通常更正式、克制、间接；面对亲密对象时则更直接、情绪化或带有安抚性。

本项目的五类角色可以映射到不同语用维度：

表 6: 角色语用特征				
对象	权力关系	社会距离	场景领域	表达重点
老板	对方较高	远	工作	正式、结果、进度
同事	平级	中	工作	协作、边界、礼貌
好朋友	平级	近	生活	随意、直接、自然
女朋友	平级	最近	恋爱	亲密、温柔、情绪关照
母亲	长辈	近	家庭	尊重、温暖、让长辈放心

6.2 语域理论

语域理论认为，语言形式会随场域、语旨和语式变化。场域对应谈论内容，语旨对应参与者关系，语式对应交流媒介。本项目中的“角色风格”主要属于语旨变化：同一内容因参与者关系不同而改变表达方式。

例如，工作内容对老板表达时会突出责任和安排，对朋友表达时可能变为吐槽或说明，对母亲表达时则可能弱化压力、强调安全。这说明关系风格迁移不仅是词汇替换，也涉及信息组织结构的变化。

6.3 语言顺应论

语言顺应论强调，说话者会根据交际对象、语境和目的动态调整语言选择。本项目中的模型目标可以理解为学习一种自动化的语言顺应能力：给定原句和目标对象，模型选择更适合该对象的称呼、语气和信息重点。

这一理论为数据标注和质量检查提供了依据。例如，对老板的改写不应过度情绪化，对母亲的改写不应命令式，对女朋友的改写不应像工作汇报。模型输出若违反这些关系预期，即使语义正确，也不能算高质量结果。

7 研究不足与本文定位

7.1 现有研究不足

综合以上文献，当前研究存在以下不足：

1. **风格维度较粗**：多数文本风格迁移研究集中于情感或正式度，缺少对关系对象的细粒度建模。
2. **中文角色数据缺乏**：现有中文对话数据没有提供同一语义在不同对象下的平行表达。
3. **小样本训练方案不足**：关系角色数据构建成本高，需要适合小样本的参数高效微调方案。
4. **评估体系不完善**：自动指标难以同时衡量语义保持、角色适配和自然度。
5. **系统化实现较少**：很多研究停留在离线实验，没有提供可交互的模型对比和展示平台。

7.2 本项目定位

针对上述不足，本项目将研究定位为“中文关系感知文本风格迁移”的小样本实践探索。具体贡献包括：

1. 从 LCCC 中抽取中性第一人称句子，构建五类目标对象下的中文平行改写数据。
2. 使用 DeepSeek 作为教师模型生成弱监督数据，并加入自动质检脚本提升数据可靠性。
3. 采用 mT0-large + 单 LoRA 微调，以短指令模板实现角色条件控制。
4. 开发前后端系统，支持单次改写、五角色对比、多模型对比和历史记录管理。

因此，本项目既不是单纯调用大语言模型，也不是只做离线模型训练，而是将数据构建、模型微调、评估和系统展示结合起来，形成一个完整的机器学习科研实训项目。

8 系统实现与数据闭环相关研究

前文主要讨论了中文关系风格迁移的任务定义、数据来源、模型路线和评价维度。对于本项目而言，文献综述还需要覆盖一个容易被忽略的问题：模型能力如何以可交互、可记录、可迭代的方式落地。关系风格迁移并不是一次性离线生成任务，真实使用中需要支持用户输入、角色选择、多模型对比、历史记录保存和高质量样本回收。因此，Web 系统不是附属展示页面，而是连接模型推理、人工评价和后续数据积累的工程载体。

8.1 Web 服务框架与模型推理调度

文本生成系统的后端需要同时处理请求校验、用户状态、模型调用和结果返回。传统 Flask、Django 等框架在原型开发中较常见，但其同步请求处理模式在长耗时推理任务中容易造成排队。FastAPI 建立在 ASGI 之上，支持异步请求处理，并通过 Pydantic 类型模型完成输入校验和自动接口文档生成 [24]。TechEmpower Web 框架基准测试也显示，FastAPI 在 JSON 序列化和高并发请求处理上具有较好的性能表现 [30]。这些特点使其适合承担本项目中“前端请求-后端调度-模型推理-结果返回”的接口层职责。

需要注意的是，异步 Web 框架并不自动解决模型推理的全部并发问题。如果底层 Transformers 推理是同步阻塞操作，仅把接口写成异步函数并不能提升实际吞吐。本项目的启发是：后端应将模型加载和推理封装在独立服务模块中，避免每次请求重复加载权重；对于同步推理，可通过线程池或任务队列隔离长耗时计算，防止阻塞主事件循环。五角色对比场景尤其需要这种调度能力，因为同一原句会同时触发老板、同事、朋友、恋人、母亲五类目标对象的生成请求。

8.2 数据持久化、认证与接口规范

风格迁移演示系统不仅需要返回当前结果，还需要保存历史记录和用户反馈。SQLAlchemy 是 Python 生态中成熟的 ORM 工具，能够通过声明式模型管理用户、角色、模型、改写记录和采纳样本等结构化数据，并支持关联查询和连接池管理 [25]。在科研项目快速迭代场景下，数据表结构会随着功能调整而变化，Alembic 提供的迁移脚本机制有助于记录和回滚数据库结构变化 [26]。因此，本项目采用 ORM 而不是散落的 SQL 字符串，可以降低接口层、数据层和后续导出脚本之间的不一致风险。

用户认证与数据安全同样影响系统可用性。JWT 通过令牌携带用户身份，适合前后端分离系统中的无状态认证 [27]；bcrypt 通过加盐哈希和可调计算成本提高密码存储安全性 [28]。在本项目中，这类认证机制的意义并不只是“能登录”，更重要的是把改写历史、采纳样本和用户身份关联起来，使系统能够区分普通用户反馈和管理员审核操作。

从接口设计角度看，RESTful 风格强调资源化路径和统一的请求语义 [31]。本项目中的角色列表、模型列表、改写请求、历史记录和采纳样本都可以抽象为接口资源。清

晰的 API 边界可以减少前后端联调成本，也便于后续增加“多模型对比”“五角色批量生成”“采纳样本审核”等功能。

表 7: 系统实现技术与本项目需求的对应关系

技术方向	主要作用	对本项目的意义
FastAPI 与 ASGI	接收请求、异步调度、自动生成接口文档	支撑五角色并行改写和前后端分离联调。
Pydantic 校验	定义请求体和响应体结构	约束输入文本、角色代码和模型代码，减少异常数据进入推理层。
SQLAlchemy/Alembic	管理结构化数据和表结构迁移	保存用户、角色、模型、历史记录和采纳样本，支持项目迭代。
JWT+bcrypt	用户认证与密码保护	将历史记录、采纳样本和管理员审核操作绑定到可信用户身份。
RESTful API	统一接口资源与请求语义	便于前端实现单次改写、五角色对比、多模型对比和历史查询。

8.3 用户反馈与增量训练闭环

在机器学习系统中，数据持久化不应只服务于业务记录，还应服务于模型改进。MLOps 相关实践强调，模型上线后的数据采集、质量审核、再训练和部署更新是持续优化的重要环节 [29]。对于本项目这种小样本生成任务，用户在系统中采纳或修改的改写结果具有额外价值：它们可以作为人工筛选后的弱监督样本，补充原始教师模型生成数据的不足。

因此，本项目将 `transfer_records` 表用于保存每次改写请求，将 `accepted_samples` 表用于保存用户采纳样本，并设置 `pending/approved/rejected` 等审核状态。这样做可以避免把所有用户点击都直接并入训练集，而是先通过管理员复核检查语义保持、角色适配和自然流畅，再导出为 JSONL 格式进入后续 LoRA 微调。这个流程把 Web 系统从单纯的演示入口扩展为数据积累入口，与前文提出的“LLM 教师生成 + 规则过滤 + 小模型微调”路线形成衔接。

表 8: 从系统交互到增量训练的数据闭环

环节	记录内容	质量控制重点
用户改写	原句、目标角色、模型类型、生成结果、用户 ID	保证历史记录可追溯，便于比较不同模型和角色输出。
样本采纳	用户认为可用的改写结果及其来源记录	不直接进入训练集，先进入待审核样本池。
人工审核	语义保持、角色适配、自然流畅、是否模板化	过滤语义漂移、角色不匹配和低质量表达。
标准导出	approved 样本转为训练脚本可读的 JSONL	保持字段格式与 LoRA 训练数据一致。
增量训练	与原训练集结合后继续微调	让真实使用反馈反向改善模型表现。

综上，系统实现相关技术与本文主题并非割裂关系。文本风格迁移研究解决“如何生成合适表达”，Web 服务和数据闭环则解决“如何稳定调用、比较、记录和继续改进生成结果”。对于中文多角色风格迁移这种缺少公开基准、依赖小样本数据的任务，系统化实现本身就是研究闭环的一部分。

9 结论

关系感知的中文文本风格迁移是一个具有现实意义但研究相对不足的方向。它要求模型不仅能生成流畅中文，还要理解说话对象对表达方式的影响。本文前半部分从文本风格迁移、中文对话数据、指令微调模型、LoRA 参数高效微调和语用学理论等方面梳理了本项目的算法与数据基础，指出现有研究在中文关系角色平行数据、小样本训练方案和评价体系方面仍存在不足。

在算法路线之外，本文后半部分进一步梳理了 Web 演示系统所需的工程技术基础。FastAPI、SQLAlchemy、JWT+bcrypt、数据持久化和用户反馈闭环等技术，使模型训练结果能够以可交互系统的形式落地，并为后续数据积累和模型迭代提供支撑。因此，本项目不是单纯调用大语言模型，也不是只完成离线模型训练，而是将数据构建、模型微调、质量评价和系统展示结合起来，形成较完整的机器学习科研实训闭环。

综合上述文献和工程分析，本项目选择 LCCC 作为源句来源，使用 DeepSeek 作为教师模型生成弱监督角色改写数据，采用 mT0-large + 单 LoRA 进行小样本条件下的角色条件微调，并通过前后端系统实现在线改写、五角色对比、多模型对比和历史记录管理。这一路线能够较好地服务于“小样本条件下中文多角色文本风格迁移”的研究目标，也为后续扩展更多关系对象、引入人工评价和构建增量训练机制奠定基础。

参考文献

- [1] C. Raffel *et al.*, “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” *JMLR*, 2020.
- [2] L. Xue *et al.*, “mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer,” *NAACL*, 2021.
- [3] V. Sanh *et al.*, “Multitask Prompted Training Enables Zero-Shot Task Generalization,” *ICLR*, 2022.
- [4] J. Wei *et al.*, “Finetuned Language Models Are Zero-Shot Learners,” *ICLR*, 2022.
- [5] H. W. Chung *et al.*, “Scaling Instruction-Finetuned Language Models,” *JMLR*, 2024.
- [6] N. Houlsby *et al.*, “Parameter-Efficient Transfer Learning for NLP,” *ICML*, 2019.
- [7] X. L. Li and P. Liang, “Prefix-Tuning: Optimizing Continuous Prompts for Generation,” *ACL*, 2021.
- [8] B. Lester *et al.*, “The Power of Scale for Parameter-Efficient Prompt Tuning,” *EMNLP*, 2021.
- [9] E. J. Hu *et al.*, “LoRA: Low-Rank Adaptation of Large Language Models,” *ICLR*, 2022.
- [10] J. Pfeiffer *et al.*, “AdapterFusion: Non-Destructive Task Composition for Transfer Learning,” *EACL*, 2021.
- [11] S. Rao and J. Tetreault, “Dear Sir or Madam, May I Introduce the GYAFC Dataset,” *NAACL*, 2018.
- [12] Z. Fu *et al.*, “Style Transfer in Text: Exploration and Evaluation,” *AAAI*, 2018.
- [13] V. John *et al.*, “Disentangled Representation Learning for Non-Parallel Text Style Transfer,” *ACL*, 2019.
- [14] E. Reif *et al.*, “A Recipe for Arbitrary Text Style Transfer with Large Language Models,” *ACL*, 2022.
- [15] Y. Wang *et al.*, “A Large-Scale Chinese Short-Text Conversation Dataset,” *NLPCC*, 2020.
- [16] Y. Wu *et al.*, “Sequential Matching Network: A New Architecture for Multi-turn Response Selection in Retrieval-Based Chatbots,” *ACL*, 2017.

- [17] Y. Wang *et al.*, “Self-Instruct: Aligning Language Models with Self-Generated Instructions,” *ACL*, 2023.
- [18] P. Brown and S. C. Levinson, *Politeness: Some Universals in Language Usage*, Cambridge University Press, 1987.
- [19] J. Verschueren, *Understanding Pragmatics*, Edward Arnold, 1999.
- [20] D. Biber, *Dimensions of Register Variation: A Cross-Linguistic Comparison*, Cambridge University Press, 1995.
- [21] T. Shen, T. Lei, R. Barzilay, and T. Jaakkola, “Style Transfer from Non-Parallel Text by Cross-Alignment,” *NeurIPS*, 2017.
- [22] J. Li, R. Jia, H. He, and P. Liang, “Delete, Retrieve, Generate: A Simple Approach to Sentiment and Style Transfer,” *NAACL-HLT*, 2018.
- [23] R. Mir, B. Felbo, N. Obradovich, and I. Rahwan, “Evaluating Style Transfer for Text,” *NAACL-HLT Workshop on New Frontiers in Summarization*, 2019.
- [24] FastAPI Contributors, “FastAPI Documentation,” 2024. <https://fastapi.tiangolo.com/>
- [25] SQLAlchemy Authors, “SQLAlchemy ORM Documentation,” 2024. <https://docs.sqlalchemy.org/>
- [26] Alembic Contributors, “Alembic: Database Migrations,” 2024. <https://alembic.sqlalchemy.org/>
- [27] JWT.io, “JSON Web Token Introduction,” 2023. <https://jwt.io/>
- [28] bcrypt Developers, “bcrypt: Password Hashing for Python,” 2023. <https://github.com/pyca/bcrypt/>
- [29] 中国信息通信研究院, “人工智能研发运营体系 (MLOps) 实践指南 (2023 年),” 2023.
- [30] TechEmpower, “Web Framework Benchmarks Round 21,” 2024. <https://www.techempower.com/benchmarks/>
- [31] R. Fielding, “Architectural Styles and the Design of Network-based Software Architectures,” PhD Thesis, UC Irvine, 2000.